

## Capítulo

# 3

### **Técnicas de Processamento Digital de Imagens Aplicadas à Área da Saúde. XIII Escola Regional de Informática da SBC - Paraná**

Prof. Dr. Jacques Facon  
PUCPR-Pontifícia Universidade Católica do Paraná

#### ***Abstract***

*The field of Image Processing became a great search and study area. This area aims to reproduce the human ability in processing and interpreting picture information. This work aims to present the main modules of a typical Medical Image Processing and Analysis System: data acquisition, preprocessing, segmentation, feature extraction. The relevant aspects of each process are given, filtering and segmentation techniques applied to extract the interested data.*

#### ***Resumo***

*Este meta-artigo, no âmbito de projetos multidisciplinares, objetiva mostrar como a área de Processamento Digital de Imagens, por sua versatilidade e abrangência, pode ser um grande aliado à área de Saúde para solucionar desafios socio-médicos. Do ponto de visto genérico, a área de Processamento Digital de Imagens tem como meta reproduzir, de forma computacional, a capacidade humana de processar e interpretar informações picturais. Este meta-artigo tem como objetivo apresentar processos chaves envolvidos no Processamento Digital de Imagens Médicas. São descritas as técnicas de filtragem e de segmentação necessárias á extração da informação de interesse.*

#### **3.1. Introdução**

O sentido da visão pode ser considerado o meio mais eficiente de que o ser humano dispõe para captar as informações originadas no ambiente que o cerca. Algumas aplicações de imagens e alguns tipos de imagens requerem uma interação visual bastante intensa [Shi87]. A capacidade humana para processar e interpretar imensas quantidades de dados

de natureza visual motivou e ainda motiva o desenvolvimento de técnicas e dispositivos, de modo a estender esta sua capacidade e sensibilidade ainda mais. O conhecimento de como reage o sistema visual humano e de algumas técnicas disponíveis para melhor adequar a imagem à aplicação são importantes para poder explorar mais eficientemente os recursos de sistemas de processamento de imagens [FF87]. A utilização da imagem na forma digital torna possível o seu processamento computacional, aumentando sua qualidade.

## **3.2. A visão humana**

### **3.2.1. Introdução**

O sistema visual humano refere-se ao complexo sistema biológico que permite ao homem a interpretação da radiação eletromagnética do espectro visível. Este abrange as operações fisiológicas do olho humano, seu processo de conversão desta radiação em sinais neuronais e operações de processamento de baixo, médio e alto nível que ocorrem em diversas áreas do cérebro.

- **Emissão de sinais luminosos por reflexão da luz**

Os raios luminosos, provenientes de fontes externas, são refletidos pelas superfícies dos objetos, dando assim, origem a sinais que vão de encontro ao sistema visual.

- **Recepção dos sinais luminosos pelo sistema visual**

Para que esses sinais sejam recebidos adequadamente, são necessários ajustes de foco e de luminosidade, assim como a existência de uma superfície sensível à luz. Num sistema orgânico, o cristalino, o tamanho da pupila e a retina, respectivamente, fazem o papel requerido. De modo análogo ao de uma câmara fotográfica que focaliza a luz no plano do filme, a luz oriunda de uma cena é focalizada pelo cristalino do olho, formando uma imagem em receptores discretos de luz sobre a superfície da retina, células nervosas denominadas cones e bastonetes [Dou81].

Já em um sistema artificial, temos um conjunto de lentes, um mecanismo de movimentação das mesmas, um diafragma e uma superfície sensível que depende do sistema em utilização.

- **Transformação dos sinais luminosos pela superfície sensível**

A retina é composta por células nervosas sensíveis à intensidade e ao comprimento de onda da luz. Essas células transformam as respectivas informações em sinais nervosos, os quais são remetidos ao cérebro pelo nervo óptico. A resolução de detalhes finos está principalmente ligada ao fato de que vários cones podem estar conectado a uma única terminação nervosa. A grande área de distribuição dos bastonetes na retina e o fato de que vários destes estão conectados a uma única terminação nervosa reduz a quantidade de detalhes discerníveis por estes receptores. Os cones são extremamente sensíveis a cores e estão concentrados em uma pequena região central, enquanto que o restante da retina consiste numa mescla de cones e bastonetes. Portanto, o olho possui amostragem espacial e características de resolução não lineares.

Para atender as exigências do mundo industrial, existe hoje uma diversidade muito grande de sensores que permitem transformar intensidades luminosas em sinais e imagens digitais.

- **Armazenamento da informação**

A informação é armazenada em uma memória compatível com o sistema em questão. Existe uma série de teorias sobre o funcionamento da memória animal assim como uma grande quantidade de tipos de memórias no mercado. O principal é que o sistema seja capaz de armazenar as informações por um determinado período de tempo e de ter acesso de modo eficiente a essas quando necessário [CDG92].

- **Processamento da informação**

A informação, uma vez recebida e armazenada, é processada de acordo com a configuração do sistema. A configuração está determinada pela evolução do organismo, assim como por processos de assimilação e/ou adaptação do mesmo. Existem várias teorias de compreensão do processamento da informação pelo cérebro. Uma abordagem é considerar que o cérebro leva em conta uma base de dados para efetuar uma comparação entre a informação recebida e alguns padrões de situações semelhantes armazenados nessa base.

- **Resposta Nervosa**

De uma forma geral, o cérebro fornece para a entidade envolvida no processo (braço, perna, etc...) uma resposta dependente da semelhança encontrada ou não encontrada e prepara o comportamento adequado. Caso encontrar um padrão desconhecido ou novo, o cérebro tem a faculdade de classificá-lo na base de dados e então enriquecê-la.

### 3.2.2. Características do sistema visual humano

- **Assimilação da informação**

O número e a natureza de padrões que os sistemas visuais orgânicos são capazes de processar fazendo a devida assimilação e adaptação contínua do sistema é extremamente elevada. O atual conhecimento científico e tecnológico não permite tal desempenho e uma escolha com perda significativa de informação é em geral efetuada.

- **Eficiência do processamento**

O tempo com que os sistemas orgânicos desempenham o processamento da informação é o suficiente e o necessário para a sobrevivência dos organismos. Já a eficiência do processamento artificial impõe sérias restrições ao tempo de resposta necessário a muitas aplicações.

- **Diversidade do ambiente**

Enquanto um filme fotográfico ou uma máquina fotográfica digital possui um único nível de sensibilidade, a retina pode adaptar sua sensibilidade em uma vasta gama, por meio de adaptações químicas em seus receptores e pelo fato dos bastonetes serem especializados para baixas intensidades luminosas (visão scotópica) e os cones para altas intensidades (visão fotópica). A retina pode também adaptar-se

a variações locais que ocorrem numa imagem, mudando o limiar de sensibilidade de células receptoras individuais. Já um filme ou uma máquina fotográfica digital não tem essa flexibilidade.

A habilidade do olho em discriminar entre vários níveis de brilho é uma consideração importante para a apresentação dos resultados do processamento de imagens. A faixa dos níveis de intensidade luminosa ao qual o sistema visual humano pode se adaptar é da ordem de 1000.

Há também considerável evidência experimental de que o brilho subjetivo, que é o brilho percebido pelo sistema visual humano, seja uma função logarítmica da intensidade da luz incidente no olho. Para o sistema visual humano poder operar sobre toda a faixa de intensidades, ocorre uma mudança da sua sensibilidade global, um fenômeno conhecido como adaptação de brilho. No caso de uma cena complexa, o sistema visual não se adapta a um nível único de intensidade, mas sim a um nível médio que depende das propriedades desta cena. À medida que o olho a percorre, o nível de adaptação instantâneo flutua em torno desta média. De modo a obter uma visualização suave para o olho, para uma grande classe de tipos de imagem, normalmente é necessária uma gama com mais de 100 níveis de intensidades.

Em função dos dados anteriores, podemos constatar que a capacidade dos organismos em se adaptarem a situações novas, e às vezes adversas, é extremamente boa quando comparada com os sistemas artificiais. Condições deficientes de iluminação, informação imprecisa ou parcial, deformação da imagem e outros fatores exigem estruturas de tratamento da informação extremamente confiáveis para que o reconhecimento seja feito adequadamente.

### **3.3. Concepção de um sistema de visão artificial**

#### **3.3.1. Introdução**

Os sistemas de visão artificial visam, com o auxílio do conhecimento de diversas áreas (biologia, medicina, comunicação visual, eletrônica, matemática, mecânica fina), obter um conjunto de técnicas e metodologias que possam dar suporte ao desenvolvimento de teorias e produtos suficientemente eficientes e confiáveis para aplicações práticas. Cita-se, como exemplo, a automatização dos processos de controle de qualidade, a identificação e o reconhecimento de tumores, a identificação e classificação de produtos e a exploração de ambientes diversos.

O processamento e a análise de imagens é uma ciência que permite modificar, analisar e manipular imagens digitais, originalmente contínuas, a partir de um computador. Os algoritmos de processamento de imagens são procedimentos passo-a-passo para otimizar as operações de tratamento de imagens. A estação de processamento de imagens deve fornecer três facilidades: os meios de digitalizá-las, de visualizá-las e de manipulá-las [MV89].

Estas considerações supõem que o sistema seja dotado de ferramentas que permitam atingir esses objetivos. Um sistema genérico mínimo de processamento de imagens é constituído de captadores de visão, de uma parte para aquisição-digitalização de imagens,

uma memória para as mesmas, um computador que pode ter acesso a essa memória e um conjunto de ferramentas que permita visualizar o conteúdo da memória. Então, o sistema adquire, processa e visualiza imagens.

Um sistema de visão é constituído de :

- **Sensores de Visão**

Estes fornecem uma projeção da cena de trabalho e realizam a aquisição de imagens. Existem diversas maneiras de gerar imagens, por câmera, máquina fotográfica digital, raio-X, ultrason, infravermelho, scanner, tomografia etc.. Às vezes, a possibilidade de acoplar um sistema de iluminação pode permitir a obtenção de imagens de melhor contraste e de melhor qualidade, reduzindo assim a quantidade de processamentos preliminares.

- **Hardware de Digitalização de Imagens**

Este tem como alvo colocar a imagem do sensor na memória. O módulo de aquisição permite escrever de modo eficiente na memória que pode ser lida pelo computador e pelo módulo de visualização. O módulo de digitalização transforma as imagens contínuas em imagens digitais. O alvo dessa transformação é quantificar a qualidade, o contraste, as diferenças de cores da cena. O digitalizador cria uma imagem digitalizada, representada por uma matriz de números, cujos elementos são chamados pixels. Devido à evolução do mundo industrial, a grande maioria dos sensores transformam diretamente intensidades luminosas em sinais e imagens digitais.

- **Computador**

Este executa os algoritmos de processamento de imagens permitindo flexibilidade e custos de processamento e de memória relativamente baixos. Os algoritmos são desenvolvidos para, em condições de iluminação a priori variáveis, possibilitar a escolha da informação adequada nas imagens, a ser interpretada e a partir da qual serão tomadas as decisões.

### **3.3.2. Arquitetura de um sistema de visão artificial**

O processamento e a análise de imagens é uma ferramenta multidisciplinar e se presta à utilização para fins diversos. Os processamentos mudam muito em função da área de trabalho. Os tratamentos variam sobre as imagens segundo:

- **A natureza das imagens**

A natureza das imagens provém das áreas como medicina, do meio industrial ou de laboratório, onde as entidades encontradas e informações contidas são muito diversas.


- **A qualidade das imagens**

Os requisitos de qualidade de uma imagem variam de acordo com a aplicação. A resolução, que é o grau de detalhes discerníveis em uma imagem, é muito dependente das dimensões da matriz da imagem, do número de níveis de cinza de cada pixel e do intervalo entre imagens (no caso de uma sequência de imagens). Características como o número e distribuição dos detalhes e a presença de áreas com

variação gradual de brilho influem no grau subjetivo atribuído á qualidade da imagem. As condições de iluminação do ambiente estudado influenciam a qualidade das informações disponíveis (regiões, contornos, detalhes, contrastes etc...).

- **O conhecimento inicial do meio de estudo**

Ter um conhecimento inicial de uma cena é elemento importante no processo de análise. No meio industrial, o conhecimento inicial quase sempre existente permite uma análise mais dirigida para uma solução rápida. Em casos onde o conhecimento inicial é fraco, como no caso de imagens adquiridas por satélites, o processo de análise deve ser então mais completo e mais rico para suprir a falta de conhecimento.



**Figure 3.1. Estrutura funcional de um sistema de visão artificial**

Modernamente, as técnicas de processamento e análise de imagens podem ser classificadas em três níveis distintos: baixo, médio e alto [Duf86] [Mar82]. Percebe-se que ocorre uma redução progressiva da quantidade de informações manipuladas, à medida que se passa por níveis crescentes de abstração. No processamento de baixo nível, os dados de entrada são pixels da imagem original e os dados de saída representam propriedades da imagem, na forma de valores numéricos associados a cada pixel. No processamento de nível médio este conjunto de valores produz como resultado uma lista de características. O processamento de alto nível produz, a partir destas características, uma interpretação do conteúdo da imagem. Estas especificações supõem uma diversificação dos processamentos. Uma estrutura funcional de um sistema de processamento e análise de imagens pode ser descrito [Mar82] [Ros88] da seguinte forma (figura 3.1):

- **Aquisição e digitalização**

A imagem do sensor é transformada em uma imagem digital sobre a forma de uma tabela de valores discretos inteiros chamados pixels. A figura 3.1 ilustra um exemplo aquisição de uma imagem ruidosa de duas famílias de células, as azuladas e as que tendem para o marrom-avermelhado.

- **Pré-processamento**

Essa etapa permite corrigir um certo número de defeitos e imperfeições aparecidos

durante a aquisição da imagem, que podem ter como causa características físicas do sistema, as condições deficientes de iluminação, etc... O pré-processamento não é indispensável, mas, na maioria dos casos, necessário. A figura 3.1 ilustra um exemplo de remoção de ruído da imagem adquirida anteriormente.

- **Segmentação**

A meta consiste em dividir uma imagem em partes constitutivas. Em uma imagem natural, a segmentação é efetuada pela detecção de descontinuidades (contornos) e/ou de similaridades (regiões) na imagem. A maioria dos processamentos é baseada na pesquisa dessas entidades que são armazenadas numa forma adequada (segmentos ou primitivas). A figura 3.1 ilustra um exemplo de extração das duas famílias de células acima citadas.

- **Interpretação**

É a parte mais “inteligente” do processo de visão por computador: ela representa o “alto nível” e permite obter a compreensão e a descrição final do fenômeno inicial. Ela faz uso do conhecimento a priori do caso estudado e o conhecimento adquirido durante as fases precedentes. A figura 3.1 ilustra um exemplo de interpretação de células benignas e malignas.

### 3.4. Realce de imagens

#### 3.4.1. Introdução

A captura de imagens, mesmo realizado com o máximo de cuidado, é um processo que introduz uma série de degradações provenientes:

- Do próprio processo de digitalização: qualquer que seja a maneira empregada para digitalizar uma imagem (scanner, máquina fotográfica, câmera etc...), este sofre um processo de amostragem tanto das coordenadas espaciais quanto da intensidade. A consequência disto é que a qualidade da imagem, mesmo se for imperceptível ao olho nu, é sempre pior que a da cena original;
- Do equipamento usado para a digitalização: qualquer que seja este, degradações diversas são geradas que podem ser classificadas como espaciais, pontuais ou uma combinação de ambas. Por exemplo, a ausência de foco, aberrações e/ou defeitos do sistema óptico, criam degradações espaciais que agem na imagem de maneira a afetar sua resolução, deixando as transições entre regiões da imagem difusas. Por outro lado, a luz dispersa, os reflexos de luz, os sombreamentos das lentes são exemplos que podem causar degradações pontuais do tipo ruído aditivo ou multiplicativo, que distorcem os níveis de cinza, mas não nublam a imagem;
- Das condições às vezes precárias no momento da aquisição das imagens ou das limitações impostas pela situação: imagens médicas de ultrasonografia, por exemplo, são tradicionalmente imagens adquiridas em condições limitadas. Um outro exemplo é a aquisição de imagens contendo partes metálicas que geram reflexos.
- De falhas humanas: um exemplo disto é o posicionamento ou movimento inadequado do paciente no momento da geração das imagens.

As imagens monocromáticas são, de forma geral, representadas matematicamente por uma função  $f$ , onde o valor  $f(x,y)$  é uma medida do nível de cinza ou intensidade no ponto  $P(x,y)$ . A imagem digital é uma imagem que sofreu um processo de digitalização (ou ainda amostragem ou discretização) tanto das coordenadas espaciais quanto da intensidade, onde a digitalização das coordenadas espaciais refere-se á amostragem da imagem e a digitalização da intensidade refere-se á quantificação dos níveis de cinza. Uma imagem qualquer sofre sempre degradações diversas. As degradações a combater podem ser classificadas como espaciais, pontuais ou uma combinação de ambas. Degradações espaciais agem na imagem de maneira a afetar sua resolução, deixando as transições entre regiões da imagem difusas. Exemplos disto são: a ausência de foco, aberrações do sistema óptico, o movimento de entidades da imagem, etc.. Por outro lado, as degradações pontuais, como por exemplo, ruído aditivo ou multiplicativo, distorcem os níveis de cinza mas não nublam a imagem. A luz dispersa, os reflexos de luz, o sombreamento das lentes são exemplos que podem causar degradações pontuais.

Portanto, qualquer sistema de processamento e análise de imagens deve dispor de ferramentas que possam reverter o processo de degradação de maneira a resgatar o máximo de qualidade do documento. As técnicas de melhoria da qualidade de imagens podem ser divididas em duas famílias:

- técnicas de restauração : a restauração procura obter a imagem original, tendo se possível, um conhecimento a priori da degradação. Sua ênfase está na modelagem de degradações e na recuperação de imagem por inversão do processo de degradação;
- técnicas de realce: quando não é possível de antemão dispor do processo de degradação ou os padrões de degradação não podem ser avaliados.

A restauração difere de realce pelo fato de que a primeira procura obter a imagem “real” tendo, se possível, um conhecimento a priori da degradação. Sua ênfase está na modelagem de degradações e na recuperação de imagem por inversão do processo de degradação. Sua meta é a obtenção de uma imagem com entidades restauradas que diferem o menos possível daqueles da imagem “real”.

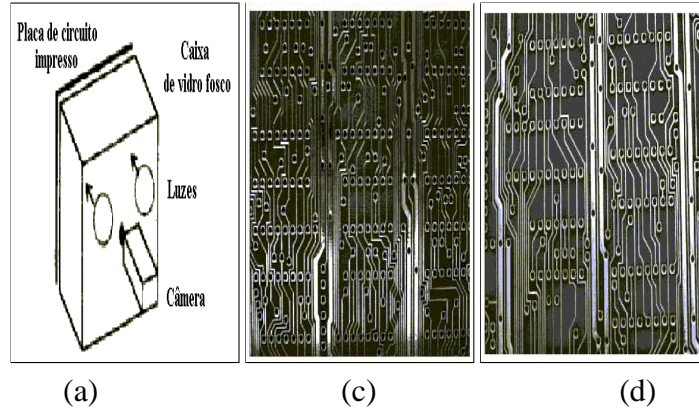
Os métodos de realce diferem dos de restauração pelo fato de que os primeiros são essencialmente projetados para manipular a imagem a partir das características psicofísicas do sistema de referência que é a visão humana.

Devido á dificuldade de se conhecer de antemão os processos de degradação e da complexidade computacional da modelagem destas degradações, faz-se pouco uso de técnicas de restauração. Basicamente, filtrar uma imagem é aplicar técnicas de realce. As técnicas de realce de imagens são relacionadas com a expansão de contraste, o realce de bordas e a eliminação do ruído. A maioria das técnicas de realce de imagens são heurísticas e orientadas para aplicações específicas. Um critério de avaliação universal ainda não existe. O sucesso da aplicação depende do julgamento subjetivo do analista. Com o realce de uma imagem, objetiva-se a obtenção de uma imagem apresentando bom contraste, contornos nítidos, riqueza de detalhes e pouco ruído. Devido a grande quantidade de técnicas de realce disponíveis na literatura serão apresentadas aqui as mais úteis e promissoras no caso de imagens médicas.



### 3.4.2. Cuidados iniciais

Como já citado anteriormente, a aquisição de imagens com partes metálicas exige cuidados especiais. Às vezes, é necessário o uso de uma estrutura especial. Um exemplo disto é a aquisição de imagens de placas de circuito impresso. A figura 3.2 ilustra um exemplo de como se pode ser concebido um sistema simples, barato e eficiente que permita adquirir uma imagem de boa qualidade de placa de circuito impresso.



**Figure 3.2. Exemplo de aquisição de imagem de placa de circuito impresso: (a) Exemplo de sistema dedicado de aquisição, (b) Imagem obtida sem sistema adequado, (c) Imagem obtida com um sistema adequado**

### 3.4.3. Aprimoramento de contraste

#### 3.4.3.1. Modificação de contraste

Para compensar os efeitos do sensor, é necessário aumentar a dinâmica. Uma modificação do contraste é uma aplicação  $t(\bullet)$  tal como:  $z' = t(z)$  onde  $z_{min} < z, z' < z_{max}$ .

Aumentar o contraste, com  $z \in [a, b] \subset [z_{min}, z_{max}]$  é  $z' = \left[ \frac{z_{max} - z_{min}}{b - a} \right] (z - a) + z_{min}$

Uma outra possibilidade quando a maioria dos níveis de cinza estão entre  $a$  e  $b$  é:

$$z' = \begin{cases} z_{min} & \text{se } z < a \\ \left[ \frac{z_{max} - z_{min}}{b - a} \right] (z - a) + z_{min} & \text{se } a < z < b \\ z_{max} & \text{se } b < z \end{cases}$$

Essa transformação quase linear comprime os intervalos  $[z_{min}, a]$  e  $[b, z_{max}]$ . Isto é aceitável quando tem-se poucos níveis de cinza nesses intervalos.

Geralmente, transformações não lineares podem ser usadas, a única restrição é que o resultado deve ficar no intervalo  $[z_{min}, z_{max}]$ .

Uma transformação  $t'(\bullet)$  desse tipo pode ser definida:  $t' = \left[ \frac{z_{max} - z_{min}}{t_2 - t_1} \right] (t(z) - t_1) + z_{min}$  onde:  $t_1 = \min t(z)$  e  $t_2 = \max t(z)$

com  $z_{min} < z < z_{max}$ .  $t'(\bullet)$  satisfazendo a condição:  $z_{min} < t'(z) < z_{max}$ .

### 3.4.3.2. Equalização de histograma

A equalização de histograma é método interessante por sua economia em termos de memória usada, por seu tempo de processamento reduzido e por ser simples e eficiente. O histograma da imagem é reformulado em um histograma diferente, que possui a propriedade de distribuição uniforme objetivando assim a melhoria do contraste da imagem. Existe na literatura vários algoritmos de equalização de histograma [CZ99] [DCT95] [KKH00] [Kim97] [Kim96].

O processo clássico de equalização de histograma pode ser formulado da seguinte maneira:

$$f(X_k) = X_0 + (X_{L-1} - X_0)C(X_k),$$

onde  $X_i$ ,  $L$  e  $C(X_k)$  representam respectivamente o nível de cinza  $i$ , o número de níveis de cinza, e  $C(X_k) = \sum_{j=0}^k P(X_j)$ ,  $P(X_j)$  sendo a probabilidade do nível de cinza  $j$ .

A Figura 3.3 exemplifica dois processos de equalização de histograma de uma imagem de ventrículo esquerdo em imagem ecocardiográfica. Este tipo de imagem se caracteriza por ser geralmente de baixo contraste. Na Figura 3.3 são exemplificadas a equalização tradicional e a equalização logarítmica baseada no modelo LIP [DCT95].




Figure 3.3. Exemplo de equalização de histograma: (a) imagem original, (b) Equalização tradicional, (c) Equalização logarítmica baseada no modelo LIP

### 3.4.3.3. Aprimoramento Local

O método precedente de equalização é global porque a intensidade de cada “pixel” é modificada em função da distribuição dos níveis de cinza da imagem inteira. Para conservar certos detalhes, recorre-se às transformações ditas locais que agem sobre as vizinhanças dos “pixels”. Existem duas maneiras de criar uma transformação local. A primeira consiste em a equalização de histograma localmente em janelas que dividem a imagem ou deslizam sobre a mesma. O algoritmo POSHE é um exemplo disto [KKH00].

Uma maneira modificação local, não é baseada sobre a noção de histograma, é a seguinte transformação:

$$g(x,y) = L(x,y)[f(x,y) - m(x,y)] + m(x,y) \quad (1)$$

onde

$$L(x,y) = k \left[ \frac{M}{\sigma(x,y)} \right] \text{ para } 0 < k < 1 \quad (2)$$

onde  $m(x,y)$  e  $\sigma(x,y)$  são, respectivamente, a média e a variância das intensidades em uma vizinhança de  $(x,y)$ ,  $M$  é a média geral e  $k$  uma constante. O termo  $L(x,y)$  amplia as variações locais,  $m(x,y)$  é somado na expressão da nova intensidade para restituir a média local.


### 3.4.4. Redução de ruído

Devido ao aspecto digital das imagens, os filtros lineares baseados no produto de convolução discreta (do tipo filtro da média) não são eficientes para reduzir o ruído numa imagem. Com os filtros lineares, o ruído aditivo, aleatório ou não correlacionado não é eliminado mas somente espalhado afetando os pixels vizinhos. Os filtros não lineares representam as técnicas mais eficientes de redução de ruído, como por exemplo, o filtro da mediana, o filtro de Nagao-Matsuyama e os filtros morfológicos.

#### 3.4.4.1. Filtro da mediana

O filtro da mediana [NR78] tem como objetivo substituir o pixel central de uma janela  $w \times w$  pelo  $k = \frac{w^2+1}{2}$ -ésimo valor dos níveis de cinza dessa janela arranjados de acordo com seu valor em ordem crescente. O filtro da mediana representa o filtro não linear mais fácil de se implementar, permitindo um ganho de qualidade mesmo em casos de imagens bastante ruidosas. Pode-se verificar que, quando aparecem valores fora do domínio da ordenação dos valores na vizinhança, a mediana da distribuição não é alterável. O que demonstra que a mediana é pouco sensível ao ruído de tonalidade diferente do conteúdo das regiões da imagem (figura 3.4-(c)).

Em geral, esse tipo de filtro destrói pontos isolados e, às vezes, linhas bem finas. Mas de forma geral ele respeita as transições. Além disso, ele é eficiente para ruídos do tipo pulso. Se o ruído numa imagem aparece como erro aditivo, aleatório ou não correlacionado, os pixels afetados são, pelo filtro da Mediana, corrigidos com a vantagem de evitar espalhar o efeito do ruído para os pixels vizinhos. Com o aumento do tamanho da janela, os resultados do filtro da Mediana continuam ótimos sem perda de nitidez tendo somente tendência em eliminar pequenas regiões. A figura 3.4 ilustra bem as diferenças de eficiência entre o filtro da média e o da mediana no caso de uma imagem de ressonância magnética do cérebro contaminada por um ruído sal-pimenta. Enquanto o filtro linear da média  $3 \times 3$  (figura 3.4-(b)) espalha o ruído, o filtro da mediana  $3 \times 3$  o elimina.



**Figure 3.4.** Exemplos de filtragem de uma imagem contaminada por ruído sal pimentado: (a) Imagem original ruidosa, (b) filtro da média, (c) filtro da mediana, (d) filtro morfológico seqüencial, (e) filtro de Nagao-Matsuyama recursivo

#### 3.4.4.2. Filtros morfológicos

A morfologia matemática, elaborada inicialmente por Georges Matheron e Jean Serra [Ser82], concentra seu esforço no estudo da estrutura geométrica das entidades presentes numa imagem. O princípio básico da morfologia matemática consiste em extrair uma informação relativa à geometria e à topologia de um conjunto desconhecido de uma imagem pela transformação a partir de um outro conjunto completamente definido chamado *elemento estruturante*. O formato e o tamanho do elemento estruturante possibilita testar e quantificar de que maneira este "*está ou não está contido*" na imagem. A morfologia matemática oferece uma ampla gama de operadores de processamento de imagens, o que lhe confere uma grande flexibilidade. Uma vantagem da morfologia matemática é que a grande maioria de seus operadores baseiam-se em poucos operadores básicos. Existe 4 operadores morfológicos básicos:

- Erosão: A erosão de uma imagem  $f$  por um elemento estruturante  $g$  é por definição [Ser82] (página 443):

$$\text{ero}^g(f(x)) = \text{Min}\{f(y) - g(x - y) : y \in E\} \quad (3)$$

onde a erosão não é definida num ponto onde o elemento estruturante não está abaixo do sinal  $f$ .

- Dilatação: A dilatação de uma imagem  $f$  por um elemento estruturante  $g$  é por definição [Ser82] (página 443):

$$\text{dil}^g(f(x)) = \text{Max}\{f(y) + g(x - y) : y \in E\} \quad (4)$$

- Abertura: As propriedades de iteratividade da erosão e da dilatação em níveis de cinza permitem criar novos operadores. A abertura de uma imagem  $f$  por um elemento estruturante  $g$  consiste em erodir  $f$  por  $\tilde{g}$  (transposto de  $g$ ) e em seguida dilatar o conjunto erodido por  $g$ :

$$\text{abc}^g(f) = \text{dil}^g(\text{ero}^{\tilde{g}}(f)) \quad (5)$$

- Fechamento: O fechamento é a operação dual da abertura. O fechamento de uma imagem  $f$  por um elemento estruturante  $g$  consiste em dilatar  $f$  por  $\tilde{g}$  (transposto de  $g$ ) e em seguida erodir o conjunto dilatado por  $g$ :

$$\text{fec}^g(f) = \text{ero}^g(\text{dil}^{\tilde{g}}(f)) \quad (6)$$

A figura 3.4-(d) exemplifica um processamento morfológico chamado filtro morfológico seqüencial abertura-fechamento com um elemento estruturante  $3 \times 3$  cruz que ilustra a eficiência na eliminação de ruído no caso de uma imagem de ressonância magnética do cérebro contaminada por um ruído sal-pimenta.

### 3.4.4.3. Filtro de Nagao-Matsuyama

Nagao e Matsuyama [NM79] propuseram um método eficiente de aprimoramento de nitidez baseado em 9 máscaras, das quais 8 são assimétricas. São avaliados 9 médias e 9 desvios padrões. O princípio desse filtro é substituir o pixel central  $P(x,y)$  da vizinhança por um novo pixel cujo valor é a média da máscara que fornece o menor desvio padrão, seja ainda a menor variância. Uma versão recursiva deste filtro, que converge automaticamente numa filtragem ótima, pode ser implementada. Esse filtro não se comporta bem com imagens ruidosas. Ele pode suprimir alguns pontos isolados mas tem tendência a reforçar o ruído, caso a imagem for muito ruidosa. Mas a força desse filtro reside no realce das transições e da nitidez da imagem. Isto apesar de um esforço computacional elevado. A figura 3.4-(e) ilustra a eficiência em termos de aprimoramento de nitidez deste filtro no caso de uma imagem de ressonância magnética do cérebro onde o ruído foi previamente eliminado.

### 3.4.5. Realce de contornos ou bordas

#### 3.4.5.1. Introdução

Um contorno ou borda é uma mudança brusca do nível de cinza entre duas regiões relativamente homogêneas. Qualquer captor introduz uma falta de nitidez mais visível especificamente nas bordas das regiões que compõem a imagem. Bordas representam componentes de alta frequência.

Realçar contornos consiste em localizar e enfatizar pixels nessas mudanças bruscas de níveis de cinza. O método mais comum de realce das bordas consiste em usar um operador de diferenciação que vai amplificar as altas frequências. Não deve-se esquecer que o ruído é também um componente de alta frequência. Portanto, um tratamento preliminar faz-se sempre necessário quando a imagem é ruidosa para evitar que a diferenciação amplifique ao mesmo tempo o ruído e as bordas.

Há uma grande variedade de métodos disponíveis na literatura para realçar contornos. A bibliografia é muito fértil neste assunto. A seguir apresenta-se as mais clássicas e também as mais promissoras

### 3.4.5.2. Operador de Diferenciação de Primeira Ordem

Uma das técnicas de detecção de bordas mais populares é a abordagem de diferenciação local. Um operador de diferenciação é baseado na noção de derivada. Uma imagem  $I(x,y)$  é uma seqüência de regiões homogêneas de tamanhos diversos e de fronteiras, encontros de várias regiões, marcando transições entre elas. Do ponto de vista matemático, um região apresenta derivadas fracas e uma fronteira derivadas elevadas. A abordagem de detecção de bordas que será apresentada aqui segue o princípio da derivação. Serão também propostos tipos diferentes de operadores que aproximam derivadas digitais.

Um critério primordial na elaboração de operadores de diferenciação é tentar construir operadores que sejam invariantes por translação, rotação e mudança de escala. Um operador  $O(\bullet)$  é dito invariante pela transformação  $t(\bullet)$  se e somente se aplicar o operador depois da transformação produz o mesmo resultado que realizar a transformação depois de ter aplicado o operador, seja  $t[O(I)] = O[t(I)]$ .

A transformação mais problemática é a rotação. Uma rotação pode ser definida da seguinte maneira:

$$\begin{cases} u &= x \cos \theta + y \sin \theta \\ v &= -x \sin \theta + y \cos \theta \end{cases} \quad (7)$$

onde  $(x,y)$  e  $(u,v)$  representam respectivamente as coordenadas antes e depois da rotação.

As derivadas parciais de primeira ordem de uma imagem  $I(x,y)$  podem ser formuladas da seguinte maneira:

$$\begin{cases} \frac{\partial I(x,y)}{\partial x} &= \frac{\partial I(x,y)}{\partial u} \cos \theta + \frac{\partial I(x,y)}{\partial v} \sin \theta \\ \frac{\partial I(x,y)}{\partial y} &= \frac{\partial I(x,y)}{\partial u} \sin \theta + \frac{\partial I(x,y)}{\partial v} \cos \theta \end{cases} \quad (8)$$

Estas equações mostram que as derivadas parciais de primeira ordem são invariantes por translação e mudança de escala, porém, não são invariantes por rotação. Entretanto, se utilizar derivadas de segunda ordem (Laplaciano), a invariância é verificada:

$$\left(\frac{\partial I(x,y)}{\partial u}\right)^2 + \left(\frac{\partial I(x,y)}{\partial v}\right)^2 = \left(\frac{\partial I(x,y)}{\partial x}\right)^2 + \left(\frac{\partial I(x,y)}{\partial y}\right)^2$$

### 3.4.5.3. Gradiente clássico

Objetiva-se maneiras de definir derivadas parciais de primeira ordem digitais. Sabe-se que a derivada em uma direção qualquer é função das derivadas parciais nas direções  $x$  e  $y$ . Pode-se determinar, num ponto dado  $P(x, y)$ , a direção  $\theta_0$  onde a derivada de  $I(x, y)$  atinge um máximo. Considerando que o novo sistema de referência  $(P(x, y), u, v)$  é centrado no ponto  $P(x, y)$ , e que os eixos deste sistema são obtidos por rotação dos eixos de referência  $(x, y)$  em relação ao ângulo  $\theta$ , tem-se:

$$\begin{cases} u = x \cos \theta + y \sin \theta \\ v = -x \sin \theta + y \cos \theta \end{cases} \quad (9)$$

onde  $(x, y)$  e  $(u, v)$  representam respectivamente as coordenadas antes e depois da rotação  $\theta$ .

Derivando  $\partial I(x, y) / \partial u$  em relação a  $\theta$ , tem-se:  $\frac{\partial I(x, y)}{\partial u} = 0 \implies -\frac{\partial I(x, y)}{\partial x} \sin \theta + \frac{\partial I(x, y)}{\partial y} \cos \theta = 0$

Se  $\theta_0$  representa a direção do máximo da derivada de  $I(x, y)$ , então  $\theta_0$  é dado por:  $\theta_0 = \arctan\left(\frac{\partial I(x, y) / \partial y}{\partial I(x, y) / \partial x}\right)$ .  $\theta_0 + \pi$  é também uma solução. Pode-se verificar que em uma direção, tem-se um máximo, na outra um mínimo.

$$\begin{cases} \cos \theta_0 = (1 + \tan^2 \theta)^{-\frac{1}{2}} \\ \sin \theta_0 = (1 - \tan^2 \theta)^{-\frac{1}{2}} \end{cases}$$

O valor máximo de  $\partial I(x, y) / \partial u$  é obtido pela equação:

$$\frac{\partial I(x, y)}{\partial x} \cos \theta_0 + \frac{\partial I(x, y)}{\partial y} \sin \theta_0 = \sqrt{\left(\frac{\partial I(x, y)}{\partial x}\right)^2 + \left(\frac{\partial I(x, y)}{\partial y}\right)^2}$$




Figure 3.5. Interpretação das informações extraídas pelo gradiente

O vetor desta amplitude na direção  $\theta$  chama-se vetor **GRADIENTE**  $G$  no ponto  $P(x, y)$  da imagem  $I(x, y)$ . Esse vetor  $G$  expressa ao mesmo tempo a maior variação e a direção da maior variação da descontinuidade no ponto (figura 3.5) e é caracterizado por seu módulo e seu ângulo :

• **módulo:**

$$||G[P(x,y)]|| = \sqrt{G_x^2 + G_y^2} = \sqrt{\left(\frac{\partial}{\partial x}\right)^2 + \left(\frac{\partial I}{\partial y}\right)^2} \quad (10)$$

• **ângulo:**

$$\theta = \arctan\left(\frac{G_y}{G_x}\right) = \arctan\left[\frac{\left(\frac{\partial I}{\partial y}\right)}{\left(\frac{\partial I}{\partial x}\right)}\right] \quad (11)$$

No caso de uma imagem digital, é preciso aproximar as derivadas parciais. Existem vários operadores de avaliação das derivadas parciais. Muitos desses operadores são lineares baseados na convolução discreta. Convoluir uma imagem  $I(x,y)$  com uma máscara  $F(x,y)$ ,  $x \in [0, M-1]$  e  $y \in [0, N-1]$  consiste em  $(\frac{1}{MN}) \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} I(m,n)F(x-m, y-n)$ .

Os operadores que dão uma boa aproximação levam à 8-vizinhança. Por exemplo o operador de Prewitt, de Sobel etc... O Operador 1 de Sobel caracteriza-se por:

$$[G_x] = \begin{vmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{vmatrix}$$


$$[G_y] = \begin{vmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{vmatrix}$$

A construção da imagem gradiente pelos operadores de Prewitt e de Sobel segue o mesmo mecanismo. A operação consiste em deslizar sobre toda a imagem uma janela do tamanho da máscara. Num pixel dado, os valores da máscara são multiplicados pelos valores dos níveis de cinza dos pontos correspondentes vizinhos desse pixel. A soma dessas multiplicações representa o valor do operador aplicado ao pixel central dessa vizinhança. As figuras 3.6-(c), (d) e (e) ilustram respectivamente o módulo do Gradiente e os Gradientes  $G_x$  e  $G_y$  numa imagem em níveis de cinza de fibras musculares.

#### 3.4.5.4. Gradiente otimizado

Segundo [Shi], embora o uso do gradiente através de seus operadores clássicos seja largamente utilizado, dois efeitos não desejados são gerados com o cálculo, e portanto considerados como erros. O primeiro efeito intrínseco encontrado com a aplicação do gradiente em uma imagem é a suavização. O fenômeno de suavização pode ser observado como um certo borramento da imagem. Este fenômeno é causado pela máscara do gradiente que leva em consideração os pixel de sua vizinhança. O segundo erro se dá pela diferença observada entre dos resultados obtidos pelo gradiente em sua forma discreta e sua forma contínua. Tal erro é resultante da forma de como é calculada a derivada de uma função discreta e que certamente difere da definição matemática do gradiente que considera funções contínuas. Esta segunda fonte de imprecisão do gradiente é uma inconsistência própria do operador, podendo apenas ser minimizada e não eliminada.





**Figure 3.6. Exemplo de diferenciação de primeira ordem: (a) imagem original, (b) Gradiente morfológico por erosão, (c) Módulo do gradiente pelo operador 1 de Sobel, (d) Gradiente  $G_x$ , (e) Gradiente  $G_y$**

O algoritmo proposto por [Shi] considera que, para aprimorar os resultados do gradiente, é mais importante reduzir a inconsistência própria do operador do que o efeito intrínseco de suavização. A solução numérica obtida no caso do gradiente  $3 \times 3$  é ilustrada a seguir:

$$[G_{x_{otimizado}}] = \begin{vmatrix} 0.112737 & 0 & -0.112737 \\ 0.274526 & 0 & -0.274526 \\ 0.112737 & 0 & -0.112737 \end{vmatrix}$$

A solução no caso do gradiente  $5 \times 5$  é mostrada a seguir. Neste caso a suavização da imagem ocorre em conjunto com a otimização.

$$[G_{x_{otimizado}}] = \begin{vmatrix} 0.003776 & 0.010199 & 0 & -0.010199 & -0.003776 \\ 0.026786 & 0.070844 & 0 & -0.070844 & -0.026786 \\ 0.046548 & 0.122572 & 0 & -0.122572 & -0.046548 \\ 0.026786 & 0.070844 & 0 & -0.070844 & -0.026786 \\ 0.003776 & 0.010199 & 0 & -0.010199 & -0.003776 \end{vmatrix}$$

### 3.4.5.5. Gradiente Morfológico

A morfologia matemática também possibilita a geração do gradiente e do laplaciano. Do ponto de visto digital, o gradiente morfológico pode ser definido das seguintes maneiras:

- Gradiente morfológico por erosão: O gradiente morfológico por erosão  $\mathbf{grad}_{ero}^g$  de uma imagem  $f(x)$  por um elemento estruturante  $g$  é  $\mathbf{grad}_{ero}^g(f) = f - \mathbf{ero}^g(f)$
- Gradiente morfológico por dilatação: O gradiente morfológico por dilatação  $\mathbf{grad}_{dil}^g$  de uma imagem  $f(x)$  por um elemento estruturante  $g$  é  $\mathbf{grad}_{dil}^g(f) = \mathbf{dil}^g(f) - f$
- Gradiente morfológico por erosão-dilatação: [Beu77] propôs uma avaliação do gradiente morfológico a partir de erosão e da dilatação efetuadas a partir de um elemento estruturante disco de raio unitário:

$$\text{Gradiente}(x) = \lim_{\lambda \rightarrow 0} \frac{(f \mathbf{dil} \lambda g) - (f \mathbf{ero} \lambda g)}{2\lambda} \quad (12)$$

De maneira prática, é possível implementar este Gradiente morfológico da seguinte maneira:

$$\mathbf{grad}_{ero-dil}^g(f) = \mathbf{dil}^g(f) - \mathbf{ero}^g(f) \quad (13)$$

A figura 3.6-(b) exemplifica o Gradiente morfológico por erosão-dilatação a partir de um elemento estruturante 3x3 em cruz numa imagem em níveis de cinza de fibras musculares.

### 3.4.6. Operador de Diferenciação de Segunda Ordem

Em muitas aplicações, a largura da borda não é uma preocupação. Em outras, como em visão computacional, é muito importante. Os operadores de gradiente discutidos anteriormente trazem desvantagens. A primeira delas é que eles produzem bordas de vários pixels de largura. Portanto fica difícil localizar os centros destas bordas. Isto é especialmente verdadeiro para bordas com variação suave. Se torna necessário empregar técnicas de afinamento (thinning) para reduzir a largura das bordas para um pixel.

Idealmente, um detetor de bordas deveria indicar as bordas em seu centro. Neste sentido, detetores de bordas por derivadas de segunda ordem produzem uma melhor localização das bordas.

A segunda desvantagem, já mencionada anteriormente, é que as derivadas parciais de primeira ordem não são invariantes por rotação. Esta invariância é somente verificada no caso de derivadas de segunda ordem:

$$\left( \frac{\partial I(x,y)}{\partial u} \right)^2 + \left( \frac{\partial I(x,y)}{\partial v} \right)^2 = \left( \frac{\partial I(x,y)}{\partial x} \right)^2 + \left( \frac{\partial I(x,y)}{\partial y} \right)^2$$

### 3.4.6.1. Laplaciano

O Laplaciano representa o exemplo clássico de derivadas de segunda ordem:

$$\Delta^2 I(x, y) = L[I(x, y)] = \frac{\partial^2 I(x, y)}{\partial x^2} + \frac{\partial^2 I(x, y)}{\partial y^2} \quad (14)$$

A versão digital do Laplaciano mais clássica é definida da seguinte maneira:

$$\Delta^2 I(x, y) = I(x+1, y) + I(x-1, y) + I(x, y+1) + I(x, y-1) - 4I(x, y)$$

O que, de forma prática, expressa-se pela seguinte máscara:

$$[L] = \begin{vmatrix} 0 & 1 & 0 \\ 0 & -4 & 0 \\ 0 & 1 & 0 \end{vmatrix}$$

A construção da imagem *laplaciana* segue o mesmo mecanismo que o usado pelo Gradiente. A figura 3.7-(b) exemplifica o Laplaciano numa imagem em níveis de cinza de fibras musculares.

### 3.4.6.2. Laplaciano otimizado

Embora o operador Laplaciano definido pela equação 14 seja invariante por rotação, na prática, aproximações matemáticas são feitas para que o operador possa ser aplicado ao processamento de imagens digitais. Tais aproximações fazem com que o Laplaciano perca a característica de invariância à rotação. Em outras palavras, se aplicar o Laplaciano sobre duas arestas idênticas orientadas por ângulos diferentes obter-se-á resultados diferentes. Esta anisotropia nos resultados influi muito em qualquer processamento que envolva o operador. A anisotropia do Laplaciano é um problema bem conhecido.


[KPKPR99] propôs um modelo geral de cálculo de um operador cujo os resultados de sua aplicação se aproximam ao máximo do comportamento isotrópico do operador Laplaciano na sua definição.

$$[L(\omega)] = \begin{vmatrix} (1-\omega)/2 & \omega & (1-\omega)/2 \\ \omega & -2(1+\omega) & \omega \\ (1-\omega)/2 & \omega & (1-\omega)/2 \end{vmatrix}$$

Embora não seja possível construir um Laplaciano simples que reduz totalmente o problema de anisotropia, [KPKPR99], a partir deste modelo geral, mostrou que uma máxima redução da anisotropia é atingida com o valor de  $\omega = 0.5$ .

$$[L_{otimizado}] = \begin{vmatrix} 0.25 & 0.5 & 0.25 \\ 0.5 & -3 & 0.5 \\ 0.25 & 0.5 & 0.25 \end{vmatrix}$$

A figura 3.7-(b) exemplifica o Laplaciano otimizado numa imagem em níveis de cinza de fibras musculares.



**Figure 3.7. Exemplo de diferenciação de segunda ordem: (a) imagem original, (b) Laplaciano, (c) Laplaciano otimizado ( $w = 0.5$ ), (d) LoG: Laplaciano Gaussiano, (e) DoG: Diferença de Gaussinas**

### 3.4.6.3. Laplaciano Morfológico

O Laplaciano morfológico **Laplac** de uma imagem  $f(x)$  por um elemento estruturante  $g$  pode ser definido da seguinte maneira:

$$\mathbf{Laplac}^g(f) = \frac{1}{2} (\mathbf{dil}^g(f) + \mathbf{ero}^g(f) - 2f) \quad (15)$$

### 3.4.7. Operador de Determinação de passagens por zero (zero crossings)

O método de detecção das passagens por zero a partir de um limiar consiste em convoluir a imagem com uma janela  $3 \times 3$  e buscando valores máxima e mínima nela. Se a diferença entre valores máxima e mínima ultrapassa um certo limiar, uma borda foi detectada. O número de bordas aumenta na medida que o valor do limiar diminui.

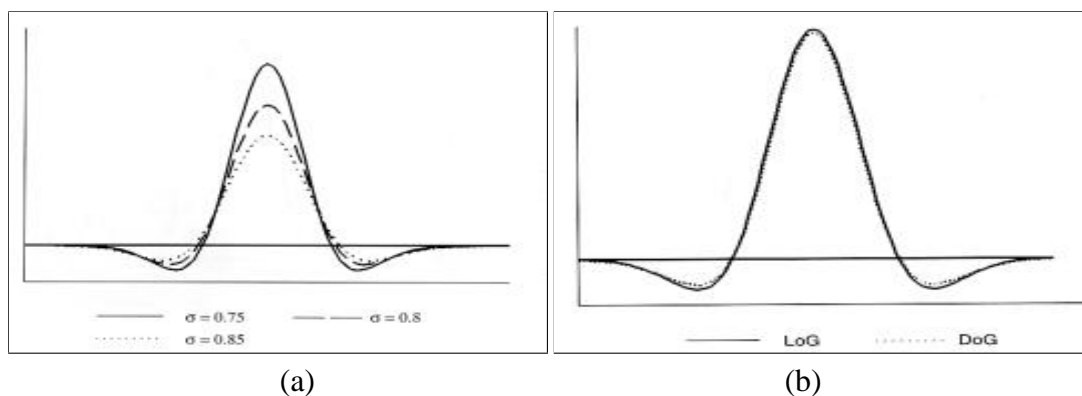
O operador de derivada de segunda ordem menos sensível ao ruído é o operador Laplaciano Gaussiano *LoG*. Este detector realiza uma suavização antes de aplicar o op-

erador Laplaciano. Ambas operações podem ser realizadas por convolução da seguinte maneira:

$$LoG = \frac{1}{\pi\sigma^4} \left[ 1 - \frac{x^2 + y^2}{2\sigma^2} \right] e^{-\frac{(x^2 + y^2)}{2\sigma^2}}$$

onde  $x$ ,  $y$  representam as linhas e colunas da imagem, e  $\sigma$  é o valor de dispersão que controla o efeito "spread". A figura 3.8 ilustra uma função  $LoG$  com vários valores de  $\sigma$ .

Devido a seu formato, a função chama-se também *filtro chapéu Mexicano*. A figura 3.8-(a) mostra a seção do operador  $LoG$  com diferentes valores de  $\sigma$ . Mais larga fica a função, mais largas ficarão as bordas detectadas. A função permite detectar bordas mais acentuadas e com mais detalhes. Maiores forem os valores de  $\sigma$ , maior for a máscara de convolução.



**Figure 3.8. (a) Seção do operador  $LoG$  com diferentes valores de  $\sigma$ , (b) Função  $LoG$  versus função  $DoG$**

O primeira passagem por zero da função  $LoG$  é para  $\sqrt{2}\sigma$ . Ter uma máscara de convolução que contém valores não nulas da função  $LoG$  exige uma largura 3 vezes maior que a largura do "lobe" central positivo ( $8.49\sigma$ ). A detecção de bordas baseada na função de suavização Gaussiana reduz o ruído da imagem, permite reduzir a detecção de falsas bordas e também detectar bordas mais largas. O tamanho da maioria das máscaras de detetores de bordas raramente ultrapassa  $7 \times 7$ . O formato do operador  $LoG$  requer máscaras mais largas, ao redor de  $35 \times 35$ . O que inviabiliza o uso deste operador. No lugar, usa-se uma aproximação, o operador  $DoG$  abaixo descrito:

$$DoG = \frac{e^{-\frac{(x^2 + y^2)}{2\sigma_1^2}}}{2\pi\sigma_1^2} - \frac{e^{-\frac{(x^2 + y^2)}{2\sigma_2^2}}}{2\pi\sigma_2^2}$$

Realiza-se o operador  $DoG$  por convolução com uma máscara que é o resultado da subtração de duas máscaras Gaussianas com valores diferentes. A razão  $\sigma_1/\sigma_2 \equiv 1.6$  resulta numa boa aproximação do operador  $LoG$ . A figura 3.8-(b) compara uma função  $LoG$  (com  $\sigma = 12.35$ ) com uma função  $DoG$  (com  $\sigma_1 = 10$  e  $\sigma_2 = 16$ ).

Uma vantagem do operador  $DoG$  reside na sua aptidão em especificar a largura de bordas a serem detectadas por variação dos valores de  $\sigma_1$  e  $\sigma_2$ . Abaixo são apresentadas

0	0	-1	-1	-1	0	0
0	-2	-3	-3	-3	-2	0
-1	-3	5	5	5	-3	-1
-1	-3	5	16	5	-3	-1
-1	-3	5	5	5	-3	-1
0	-2	-3	-3	-3	-2	0
0	0	-1	-1	-1	0	0

0	0	0	-1	-1	-1	0	0	0
0	-2	-3	-3	-3	-3	-2	-2	0
0	-3	-2	-1	-1	-1	-3	-3	0
-1	-3	-1	9	9	9	-1	-3	-1
-1	-3	-1	9	19	9	-1	-3	-1
-1	-3	-1	9	9	9	-1	-3	-1
0	-3	-2	-1	-1	-1	-3	-3	0
0	-2	-3	-3	-3	-3	-2	-2	0
0	0	0	-1	-1	-1	0	0	0

Figure 3.9. Operador *DoG* máscara  $7 \times 7$  e máscara  $9 \times 9$

duas máscaras  $7 \times 7$  e  $9 \times 9$  (figura 3.9). A máscara  $9 \times 9$  gera bordas mais largas que a máscara  $7 \times 7$ .

As figuras 3.7-(d) e (e) exemplificam os operadores *LoG* e *DoG* numa imagem em níveis de cinza de fibras musculares.

#### 3.4.7.1. Filtros recursivos de Canny e Deriche

As técnicas comuns de detecção de bordas apresentadas anteriormente apresentam uma serie de defeitos:

- os operadores clássicos de detecção de bordas amplificam o ruído;
- os operadores clássicos de detecção de bordas tem, às vezes, dificuldades em detectar bordas verdadeiras e também geram falsos contornos;
- a espessura das bordas obtidas pelos operadores clássicos raramente é de um pixel de largura;
- a avaliação dos resultados é de forma geral subjetiva, feito pelo olho do pesquisador, e não objetiva como deveria ser;
- a avaliação dos resultados é feita conforme o tipo e o número de imagens processadas que são, de forma geral, limitados.

Portanto, faz-se necessário definir critérios de desenvolvimento de um detetor de bordas mais eficiente. Canny [Can83] e Deriche [Der87] estabeleceram e desenvolveram operadores otimizados de suavização, e de detecção de borda. Pode-se enumerar três condições que caracterizam um bom detetor de bordas:

- **Detecção:** o operador deve fornecer uma resposta na vizinhança da borda
- **Localização:** a borda deve ser localizada com precisão
- **Unicidade:** uma borda deve provocar uma única resposta do operador de extração

Falar de filtragem necessita introduzir o tipo de borda (degrau, aresta, teto etc...) e de ruído (convolutivo, aditivo, branco, impulsional etc...) processados. As pesquisas e

conclusões de Canny e Deriche basearam-se na borda do tipo degrau, comum nas imagens, e no ruído branco, fácil de ser modelado.

Seja  $A$  a amplitude da borda degrau  $B(x)$  afetada pelo ruído branco  $\eta(x)$  de média  $E(\eta(x))$  nula e de variância  $E^2(\eta(x)) = \eta_0^2$ . Então a modelização da borda  $B(x)$  escreve-se:

$$B(x) = Ad(x) + \eta(x) \quad (16)$$

onde

$$d(x) = \begin{cases} 0 & \text{se } x \in [-\infty, 0] \\ 1 & \text{se } x \in ]0, \infty] \end{cases} \quad (17)$$

Supõe-se que a detecção efetua-se pelo produto de convolução  $**$  da borda ruidosa por uma função espacial de função de transferência  $h(x)$ , seja:

$$s(x) = h(x) ** B(x) = \int_{-\infty}^{\infty} B(x)h(x_0 - x)dx \quad (18)$$

A solução encontrada por Deriche [Der87] foi, em um primeiro passo, definir o filtro infinito ótimo em  $[-\infty, +\infty]$ . Deriche demonstrou que o filtro otimizado de suavização e detecção de bordas pode escrever-se:

$$h(x) = a_3 \varepsilon^{-\alpha|x|} \sin wx \quad (19)$$

O segundo passo consiste em usar a filtragem recursiva. Esta representa uma ferramenta bem conhecida que permite implementar filtros de resposta impulsional infinita com um baixo custo associado. Deriche mostrou que é possível implementar filtros recursivos de primeira e segunda ordem.

Considera-se o filtro  $f(x)$  contínuo e  $f(n)$  a função correspondente amostrada. A partir da teoria da transformada de Z, pode-se mostrar que a função  $f(n)$  pode ser decomposta em duas funções de transferência racionais de filtros estáveis, uma positiva definida para os valores crescentes de  $n$ ,  $f^+(n)$ , e uma negativa definida para os valores decrescentes de  $n$ ,  $f^-(n)$ .

O filtro de suavização de Deriche é o seguinte filtro recursivo:

$$s(x) = k(\alpha|x| + 1)\varepsilon^{-\alpha|x|} \quad (20)$$

A implementação faz-se da seguinte forma:

$$\begin{aligned} y^+(m) &= a_0x(m) + a_1x(m-1) - b_1y^+(m-1) - b_2y^+(m-2) \text{ para } m = 1, \dots, N \\ y^-(m) &= a_2x(m+1) + a_3x(m+2) - b_1y^-(m+1) - b_2y^-(m+2) \text{ para } m = N, \dots, 1 \\ y(m) &= y^+(m) + y^-(m) \text{ para } m = 1, \dots, N \end{aligned}$$

onde os coeficientes são:

$$\begin{cases} k &= \frac{(1-\varepsilon^{-\alpha})^2}{1+2\alpha\varepsilon^{-\alpha}-\varepsilon^{-2\alpha}} \\ a_0 &= k; \\ a_1 &= k(\alpha-1)\varepsilon^{-\alpha} \\ a_2 &= k(\alpha+1)\varepsilon^{-\alpha} \\ a_3 &= -k\varepsilon^{-2\alpha} \\ b_1 &= -2\varepsilon^{-\alpha} \\ b_2 &= \varepsilon^{-2\alpha} \end{cases}$$

O filtro de derivação de primeira ordem (Gradiente) de Deriche é o seguinte filtro recursivo:

$$d(x) = sx\epsilon^{-\alpha|x|} \quad (21)$$

A implementação faz-se da seguinte forma:

$$\begin{aligned} y^+(m) &= ax(m-1) - b_1y^+(m-1) - b_2y^+(m-2) \\ &\quad \text{para } m = 1, \dots, N \\ y^-(m) &= -ax(m+1) - b_1y^-(m+1) - b_2y^-(m+2) \\ &\quad \text{para } m = N, \dots, 1 \\ y(m) &= y^+(m) + y^-(m) \\ &\quad \text{para } m = 1, \dots, N \end{aligned}$$

onde os coeficientes são:

$$\begin{cases} s &= -\frac{(1-\epsilon^{-\alpha})^2}{\epsilon^{-\alpha}} \\ a &= s\epsilon^{-\alpha} \\ b_1 &= -2\epsilon^{-\alpha} \\ b_2 &= \epsilon^{-2\alpha} \end{cases}$$

O filtro de derivação de segunda ordem (Laplaciano) de Deriche é o seguinte filtro recursivo:

$$l(x) = -(1 - k\alpha|x|)\epsilon^{-\alpha|x|} \quad (22)$$

A implementação faz-se da seguinte forma:

$$\begin{aligned} y^+(m) &= a_0x(m) + a_1x(m-1) - b_1y^+(m-1) - b_2y^+(m-2) \\ &\quad \text{para } m = 1, \dots, N \\ y^-(m) &= a_2x(m+1) + a_3x(m+2) - b_1y^-(m+1) - b_2y^-(m+2) \\ &\quad \text{para } m = N, \dots, 1 \\ y(m) &= y^+(m) + y^-(m) \\ &\quad \text{para } m = 1, \dots, N \end{aligned}$$

onde os coeficientes são:

$$\begin{cases} k &= \frac{(1-\epsilon^{-\alpha})^2}{2\alpha\epsilon^{-\alpha}} \\ a_0 &= -1; \\ a_1 &= (1+k\alpha)\epsilon^{-\alpha} \\ a_2 &= (1-k\alpha)\epsilon^{-\alpha} \\ a_3 &= \epsilon^{-2\alpha} \\ b_1 &= -2\epsilon^{-\alpha} \\ b_2 &= \epsilon^{-2\alpha} \end{cases}$$

### 3.4.7.2. Aplicação dos filtros

Lembra-se que a filosofia usada por Canny e Deriche é implementar de forma eficiente a convolução, de um sinal bidimensional,  $I(x,y)$  a partir de uma reposta impulsional in-



finita  $H(x, y)$  no objetivo de definir derivadas digitais parciais de primeira e segunda ordem otimizadas. Os resultados da convolução de  $I(x, y)$  por  $H(x, y)$ , simbolizada por  $**$ , segundo Canny são:

- Derivação de primeira ordem:

$$\begin{cases} G_x(x, y) &= I(x, y) ** H'(x) ** H(y) \\ G_y(x, y) &= I(x, y) ** H'(y) ** H(x) \end{cases}$$

- Derivação de segunda ordem:

$$L(x, y) = I(x, y) ** H''(x) ** H(y) + I(x, y) ** H''(y) ** H(x) \quad (23)$$

Aplicando os resultados de Deriche, têm-se:

- Derivação de primeira ordem:

$$\begin{cases} G_x(x, y) &= I(x, y) ** s(y) ** d(x) \\ G_y(x, y) &= I(x, y) ** s(x) ** d(y) \end{cases}$$

- Derivação de segunda ordem:

$$L(x, y) = I(x) ** s(y) ** l(y) + I(x) ** s(x) ** l(y) \quad (24)$$

### 3.4.7.3. Resultados dos filtros recursivos de Canny e Deriche

Os operadores de detecção de bordas de Canny e Deriche são atualmente considerados como os melhores em:

- detectar bordas verdadeiras e não gerar falsos contornos;
- gerar bordas de um pixel de largura;
- avaliar de forma objetiva os resultados obtidos.

As maiores desvantagens desta abordagem são a complexidade computacional exigida e os tempos de processamento elevados.

## 3.5. Segmentação de imagens

Após ter descrito os mecanismos de correção de imperfeições, de deficiência de iluminação, de eliminação de ruído e de aprimoramento de nitidez, a próxima etapa consiste em ensinar o computador a extrair as estruturas e conjuntos baseando-se em noções de descontinuidade e de similaridade.

### 3.5.1. Introdução

Alguns psicólogos alemães no início do século (Köhler, Wertheimer, Koffka) mostraram que o ser humano, a nível da visão, efetua agrupamentos sobre o que ele percebe, baseados na proximidade, na similaridade, e na continuidade. O objetivo da segmentação é obter, a partir de uma imagem, um conjunto de "primitivas" ou "segmentos significativos" que contém a informação semântica relativa à imagem. A grande dificuldade da segmentação reside no fato de não se conhecer de antemão o número e tipo de estruturas que se encontram na imagem. Essas estruturas são identificadas a partir da geometria, forma, topologia, textura, cor ou brilho sendo escolhidas aquelas que possibilitam a melhor identificação.

A segmentação de imagens objetiva portanto particionar uma imagem em classes. Haralick [HSZ87] propõe as seguintes propriedades para um bom processo de segmentação:

- As classes devem ser mutuamente exclusivas;
- Cada classe é uniforme e homogênea com respeito a alguma característica como o nível de cinza ou textura parecida;
- Classes adjacentes devem ter valores significativamente diferentes com respeito à característica segmentada.

A etapa de segmentação de imagens é presente em qualquer projeto de processamento de imagens onde se deve decidir da existência, da localização e dos tipos de estruturas procuradas. Pela grande variedade de "primitivas" ou segmentos significativos que contém as informações semânticas, e pelas inumeráveis aplicações, a etapa de segmentação talvez seja um dos maiores desafios da área de processamento e análise de imagens.

As abordagens existentes na literatura para solucionar este desafio são múltiplas. Porém as primitivas usadas são poucos e basicamente ditas naturais", levam à noção de região, de contorno, de textura ou ainda a uma noção mista. Essa última é preferível, mas é mais complicada porque a passagem região-textura-contorno ou contorno-região-textura é mais fácil em teoria que na prática. Muitas vezes, uma noção unilateral é escolhida em razão dos tempos de execução mais curtos.

Como será visto a seguir, não existe um método simples que seja bom para todos os tipos de imagens, e nem todos os métodos são igualmente bons para um tipo particular de imagem.

Serão apresentadas a seguir algumas das metodologias mais significativas de segmentação de imagens, aqui descritas em função do tipo de primitiva empregada. e/ou do mecanismo matemático empregado.

### 3.5.2. Limiarização e multi-limiarização

#### 3.5.2.1. Introdução

O processo de digitalização gera uma imagem composta de pixels cujos níveis de cinza vão de 0 até 255. De forma geral, lida-se com imagens contendo objetos, células, texto, gráficos, todo tipo de informação. A partir de agora, chamar-se-á o primeiro plano de objetos (foreground em inglês) as regiões de interesse. E de fundo (background em inglês) todas as outras regiões consideradas como não interessantes. Para ilustrar esses conceitos, considere o exemplo de uma imagem de cromossomos. As informações importantes constituem a região do primeiro plano enquanto o resto constitui o segundo plano ou fundo. É óbvio que em função da imagem processada, essa noção de primeiro plano e de fundo pode mudar.

O princípio da *binarização* ou ainda chamado de *limiarização* consiste em separar o primeiro plano do fundo. O objetivo da binarização é marcar os pixels que pertencem às verdadeiras regiões de primeiro plano com um valor simples (ON) e as regiões de fundo (segundo plano) com uma intensidade diferente (OFF). E assim gerar o que se chama de imagem binária que é uma imagem preto-branca apresentando somente duas classes, o primeiro plano de cor preta sobre o fundo de cor branca ou o contrário (figura 3.10). Por ser de princípio muito simples, a segmentação por limiarização é provavelmente uma das técnicas de segmentação por região mais tradicionais e populares. Serão apresentadas a seguir as três abordagens de limiarização, a limiarização global, a limiarização local adaptativa e a multi limiarização.

#### 3.5.2.2. Limiarização global

Quando se busca um único valor de limiar para toda a imagem, o processo chama-se de limiarização global. O modo mais direto para selecionar automaticamente um valor de limiar de uma imagem é através de seu histograma. O histograma basicamente é uma tabela que fornece para cada nível de cinza o número de pixels correspondentes. No caso do primeiro plano ser bem diferenciado em relação ao fundo, o histograma apresentará distintamente duas classes na forma de dois picos separados por um "vale".


A limiarização global consiste, no caso de um primeiro plano mais claro que o fundo, em escolher no histograma um valor  $T$ , tal como para cada pixel  $P(x,y)$ :

$$P(x,y) = \begin{cases} \in \text{primeiro plano} & \text{se o valor de } P(x,y) > T \\ \in \text{fundo} & \text{senão} \end{cases}$$

Esse limiar  $T$  fica em algum lugar do vale. A figura 3.10 ilustra a influência do valor do limiar sobre a qualidade da limiarização.

Este processo é muitas vezes usado para dissociar o fundo das identidades presentes (células, objetos, nós de madeira etc.). A maior vantagem é que o princípio é simples e precisa de pouca memória. Contudo, existem várias desvantagens em selecionar um limiar global:


- A primeira é que as imagens nem sempre contém intensidades de primeiro e segundo planos bem diferenciados. Para muitas aplicações, devido a problemas de iluminação e de falta de qualidade da imagem, um único valor de limiar não permite resultar numa limiarização de boa qualidade. É bom lembrar que a qualidade da imagem é função do fator de refletância e do fator de iluminação. Esse último influencia fortemente a natureza dos picos do histograma. No caso de uma iluminação não uniforme sobre toda a cena, a separação dos picos e o estabelecimento do limiar ficam muito mais difíceis e muito empíricos.
- A segunda é que, especialmente para uma imagem de componentes de primeiro plano esparsos, tais como a maioria das imagens gráficas, o pico representando estas intensidades será muito menor do que o pico das intensidades de segundo plano (fundo). Esta diferença freqüentemente torna difícil encontrar o vale entre estes dois picos.



**Figure 3.10. Influência do valor do limiar sobre a qualidade da limiarização: (a) imagem original, (b) histograma, (c) limiarização com valor baixo, (d) limiarização com valor alto, (e) limiarização com valor adequado**

As dificuldades encontradas no processo de limiarização global motivou muitas pesquisas (acessar o site internet [Fac01] para conhecer os principais algoritmos). Um levantamento feito recentemente mostra que existem pelo menos 200 publicações sobre o assunto. O que inviabiliza apresentá-las aqui. Basicamente a grande maioria das técnicas busca particionar a imagem em duas classes, maximizando a variância inter-classes e minimizando a variância intra-classes. Isto faz-se empregando funções critério específicas

para cada abordagem. A Figura 3.11 ilustra dois exemplos de limiarização global de uma imagem contendo dois tipos de células. O método de Otsu [Ots79] permite binarizar todas elas enquanto que o método por matriz de co-ocorrência de Chanda et al [CM] tem como vantagem separar apenas um tipo de célula.



**Figure 3.11. Exemplos de limiarização global: (a) imagem original, (b) limiarização de Otsu , (c) limiarização de Chanda et al**


### 3.5.2.3. Limiarização local adaptativa

Devido a complexidade em selecionar um limiar global, definir valores diferentes de limiar para regiões diferentes da imagem através do uso de uma janela deslizante provou ser uma abordagem interessante. Este tipo de limiarização é chamado de *limiarização adaptativa* ou ainda *limiarização local*.

O problema principal com qualquer técnica de limiarização local é a escolha do tamanho da janela. O tamanho escolhido deve ser grande o suficiente para garantir que o número de pixels de fundo (segundo plano) incluídos sejam também grandes o suficiente para obter uma boa estimativa do valor da média, mas não tão grande como a média sobre as intensidades de segundo plano (fundo) não uniformes. A literatura fornece várias abordagens. A Figura 3.12 ilustra a influência do tamanho da janela no método de limiarização local de Bernsen [Ber86] no caso de uma imagem de retina.

### 3.5.2.4. Multi-limiarização

Dependendo do conteúdo da imagem, simplesmente particioná-la em somente duas classes, o primeiro plano e o fundo, acarreta uma grande perda de informação. Considere o exemplo de uma imagem de ressonância magnética do cérebro (figura 3.13-(a)). Nela encontram-se muitas informações valiosas e relevantes como, por exemplo, a região da parte óssea do crânio, o líquido cefaloraquidiano, a massa branca, a massa cinzenta e o tumor. Este tipo de imagem, complexa e rica em informações não pode ser simplesmente reduzida em duas classes.




**Figure 3.12.** Influência do tamanho da janela sobre a qualidade da limiarização local de Bernsen: (a) imagem original, (b) limiarização com janela =5, (c) limiarização com janela =35, (d) limiarização com janela = 65

Quando se busca em segmentar mais que duas regiões pelo processo de limiarização, o termo usado é *multi-limiarização* ou ainda *limiarização multi-nível*.

O maior problema da multi-limiarização reside em saber em quantas classes uma imagem pode ser particionada. A avaliação do número de classes é um problema específico da multi-limiarização. Os métodos de limiarização global e local partem do pressuposto que terá no final somente duas classes. Novamente a literatura fornece várias abordagens de multi-limiarização. Infelizmente a maioria delas precisam de prever de antemão do número de classes [Mar00]. Poucas abordagens são realmente automáticas. Vale a pena citar a abordagem automática de multi-limiarização de Jui-Cheng Yen [YCC95] interessante por avaliar automaticamente o número de classes usando critérios robustos.

A Figura 3.13 ilustra, no caso de uma imagem de ressonância magnética do cérebro, as vantagens de usar a abordagem de multi-limiarização de Jui-Cheng Yen que permite separar cada região do cérebro e localizar o tumor.



**Figure 3.13. Exemplo de multi-limiarização de Jui-Cheng Yen: (a) imagem original, (b) Primeira classe, (c) Segunda classe, (d) Terceira classe, (e) Quarta classe = tumor**

### 3.5.2.5. Escolha de um método de limiarização

Se a escolha de um método de limiarização é possível, o processo de multi-limiarização é com certeza o mais indicado para se realizar uma segmentação apurada. Caso não for possível, não se pode nunca esperar resultados perfeitos dos métodos de limiarização global e local. Dependendo da qualidade da imagem, pode haver buracos nas linhas, bordas rompidas na região limítrofes e regiões de pixels estranhas, fundos complexos. A suposição de que os resultados do processamento não serão perfeitos é geralmente verdadeiro como outros métodos de processamento da imagem em geral.

O procedimento recomendado é processar tanto quanto possível cada passo, mas adiar decisões que não necessitam ser executadas até passos recentes, para evitar erros irreparáveis. O adiamento, quando possível, é um princípio apropriado para todos os passos da análise de imagens (exceto, é claro, a interpretação que é o último).

Vários métodos de limiarização global e local e de multi-limiarização foram apresentados nesta seção. Nenhum método é melhor para todos os tipos de imagens e aplicações. Para problemas mais simples, onde as características da imagem não variam muito dentro dela ou entre diferentes imagens, os métodos mais simples são suficientes. Para problemas mais difíceis envolvendo ruído ou características mutáveis, métodos mais complexos geralmente são requeridos.

## 3.6. Descrição de aplicações reais

A seguir serão descritas aplicações reais na área de saúde onde será mostrada de que maneira podem ser aplicadas as ferramentas de Processamento e Análise de Imagens anteriormente explicadas e outras disponíveis em outras bibliografias. O leitor poderá na ocasião avaliar o grau de aplicabilidade dessas ferramentas para auxiliar computacionalmente especialistas dessas áreas.

### 3.6.1. Exemplo 1: Contagem automática de microorganismos de levedura de cerveja

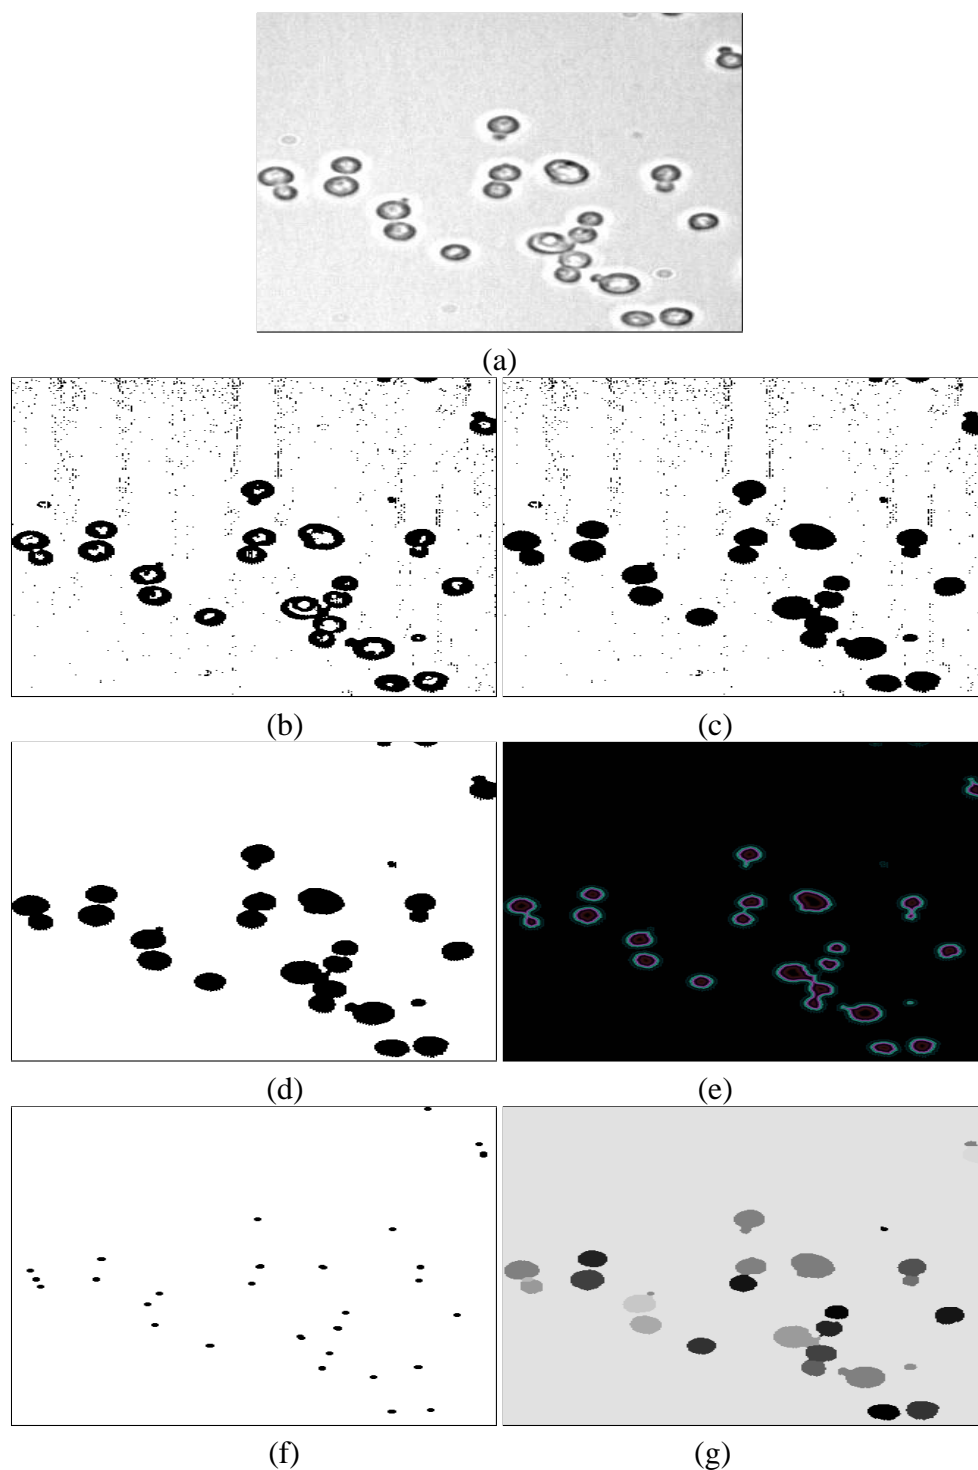
Atualmente, uma grande parte dos resíduos industriais são jogados em rios e mares. Por acarretar impactos ambientais graves, tais atitudes devem ser controladas e até proibidas.

Uma primeira maneira de evitá-las consiste em analisar a água de rios e mares depois da rejeição desses resíduos, podendo-se assim estabelecer os riscos ambientais e à saúde das pessoas quanto a presença de determinados microorganismos. Uma segunda maneira pode consistir em analisar os resíduos industriais antes de sua rejeição na água de rios e nos mares de tal modo em poder avaliar o seu poder nocivo e evitar o seu despejo. Considera-se essa segunda alternativa como sendo de suma importância na definição de atitudes ambientais corretas.

No caso da análise dos resíduos de levedura de cerveja, o procedimento tradicional em laboratórios especializados consiste em contar o número de microorganismos presentes nas amostras de água. A partir da contagem, pode-se estabelecer se o percentual causará desequilíbrio ao ambiente. Todo este processo é realizado por biólogos



ou especialistas em microbiologia que possuem um grande conhecimento sobre microorganismos, sendo assim, podem analisar e estabelecer a nocividade da presença de microorganismos.



**Figure 3.14. Contagem automática de microorganismos de levedura de cerveja: (a) Imagem original, (b) Limiarização inicial, (c) Preenchimento, (d) Filtragem, (e) Distância de Chamfer  $5/7/11$ , (e) Localização dos núcleos, (f) Separação automática por Watershed**

O processo de contagem de microorganismos de levedura de cerveja presentes na água é atualmente realizado de forma manual. O biólogo ou especialista em microbiologia efetua uma contagem manual em um número elevado de amostras de água, analisando cada uma delas através da lente de um microscópio. Assim, em função desse número, ele pode deduzir e descobrir o nível de nocividade da água com a presença dos microorganismos. Este processo manual demonstra-se ser repetitivo, portanto cansativo e sujeito à falhas humanas e à subjetividade do especialista.

Será apresentado um sistema computacional de localização e de contagem automática de microorganismos de levedura de cerveja [JÓ3].

#### **3.6.1.1. Extração dos microorganismos**

Devido à presença de ruídos e à complexidade do fundo das imagens, a localização de microorganismos de levedura de cerveja exige vários processamentos: Os microorganismos são limiarizados (ou ainda binarizados) de maneira a diferenciá-los mais facilmente do fundo ruidoso. Por produzir os mesmos resultados para imagens com iluminação variável como para imagens igualmente iluminadas, aplicou-se a técnica de limiarização adaptativa de Wellner [Wel93] com o parâmetro de porcentagem 5. Desta maneira (Figura 3.14-(b)), gera-se uma imagem binária onde os microorganismos aparecem em preto num fundo branco e onde a maioria das variações tonais desaparece.

#### **3.6.1.2. Preenchimento do interior dos microorganismos**

Depois da imagem ter sido limiarizada pela técnica de Wellner [Wel93], percebe-se que certos microorganismos apresentam-se não preenchidos, dificultando o processo de separação dos mesmos. A partir das bordas físicas da imagem (marcador), o processo de Reconstrução morfológica Binária [Fac96] Binária preenche todo o fundo da imagem limiarizada invertida (máscara) sem preencher os microorganismos. Invertendo o resultado anterior, gera-se a imagem dos microorganismos no seu formato original totalmente preenchidos sem ter sofrido qualquer deformação (Figura 3.14-(c)).

#### **3.6.1.3. Filtragem dos microorganismos**

Devido à complexidade do fundo, aparecem resíduos que podem comprometer o processo de contagem. Um processo de filtragem faz-se necessário. Uma sequência de erosão e dilatação binárias [Fac96] é aplicada sobre a imagem para eliminar tais artefatos. Resulta-se em uma imagem binária contendo somente os microorganismos no seu formato original (Figura 3.14-(d)).

#### **3.6.1.4. Separação automática dos microorganismos**

A imagem binária anteriormente obtida contém todos os microorganismos presentes na imagem original. Porém, pelo fato de vários microorganismos ficarem conectados, a

contagem precisa não é ainda possível. Separar os microorganismos conectados faz-se absolutamente necessário, e exige vários processamentos:

- Etapa 1: Faz uso de uma transformação de distância que computa numa imagem binária a distância dos pixels dos microorganismos em relação ao pixel do fundo mais próximo. Usou-se a abordagem de Chamfer 5/7/11 [Bor84] [Bor86] que permite uma boa aproximação da distância euclidiana num tempo de processamento adequado para este tipo de aplicação (Figura 3.14-(e)).
- Etapa 2: Aplica-se a técnica de Reconstrução morfológica em níveis de cinza com a imagem Distância de Chamfer 5/7/11 diminuída de 1 nível de cinza como marcador e a imagem de Distância de Chamfer 5/7/11 original, como máscara [Fac96].
- Etapa 3: A obtenção dos núcleos computacionais dos microorganismos faz-se por subtração entre a imagem resultante da Distância de Chamfer 5/7/11 original e a imagem Resultante da Reconstrução morfológica em níveis de cinza. A imagem resultante da subtração gera uma imagem que contém os núcleos computacionais dos microorganismos (Figura 3.14-(f)).
- Etapa 4: Teoricamente, cada microorganismo é representado por seu núcleo computacional. Este vai servir a rotular o microorganismo que ele representa. Portanto dois microorganismos "justapostos" ou "colados" um ao outro serão diferenciados por seus núcleos. Permitindo assim a separação de ambos. A separação dos microorganismos faz-se pela técnica de Watershed de Beucher-Meyer [BM93] que cria um rótulo diferente para cada microorganismo (Figura 3.14-(g)). A contagem automática consiste em simplesmente levantar o número de rótulos gerados.

### **3.6.2. Exemplo 2: Avaliação da proliferação celular baseada em Pcna-Ciclina por análise morfológica aplicada a linfomas malignos não-Hodgkin**

A proposta do presente trabalho é a de automatizar um processo de análise microscópica de células de tumores malignos do sistema linfático por meio de procedimentos de Processamento Digital de Imagens. E mais especificamente, realizar a contagem automática de subpopulações celulares de colorações distintas, a saber, azul e marrom.

É intensa a atividade proliferativa celular em tumores malignos. Durante o ciclo celular, podem ser identificadas moléculas, especialmente proteínas, cujo nível ou atividade variam de acordo com determinada fase deste mesmo ciclo. Ciclinas são um grupo de proteínas (proliferating cell nuclear antigens - PCNA), que se acumulam progressivamente durante a interfase e desaparecem ao final da mitose.

A reação química provocada pela interação antígeno-anticorpo faz com que as células proliferantes adquiram uma coloração específica. No caso específico da utilização do anticorpo contra a PCNA/ciclina, os núcleos proliferantes apresentam uma coloração marrom, além de, em alguns casos, tamanho ligeiramente maior que os demais, que apresentam coloração azul.

O método clássico de avaliação da proliferação celular consiste em se obter sua taxa de proliferação, razão entre o número de células proliferantes (marcadas) e o número total de células.

Executado manualmente, este método consiste em se deslizar aleatoriamente a objetiva do microscópio sobre a lâmina com o corte histológico preparado, de forma a efetuar a contagem.

A análise microscópica de cortes histológicos para fins de morfometria e quantificação, feita pelo método tradicional, é, de maneira geral, lenta, repetitiva, não acurada subjetiva, cansativa e portanto sujeita a erros humanos.

Métodos "in situ", que se baseiam na quantificação da atividade proliferativa nos próprios cortes histológicos, em virtude de suas limitações - quantificação manual, falta de padronização nos métodos de avaliação, além de ausência de correlação com outros dados prognósticos - sugerem a utilização de métodos computacionais, mais precisamente de análise de imagens para possibilitar quantificação automática.

Propõe-se desenvolver um sistema citométrico que possibilite uma contagem mais rápida e precisa a partir de uma metodologia de análise automática de imagens para avaliação do índice de proliferação celular em linfomas malignos, baseado no método imuno-histoquímico que utiliza o anticorpo monoclonal anti-PCNA-ciclina, utilizando critérios de segmentação de imagens por cor e ferramentas de morfologia matemática [Web97].

Partindo-se de uma imagem adquirida de uma lâmina, corada com o anticorpo monoclonal anti-PCNA-Ciclina, em que se podem observar duas famílias de células, as azuladas e as que pendem para o marrom-avermelhado, pode-se colocar o objetivo do método em questão: obter a taxa de proliferação celular, como sendo o número total de células proliferantes (ou marrons) sobre o número total de células (proliferantes - marrons - mais não-proliferantes - azuis) (Figura 3.15-(a)).


A segmentação inicial entre o fundo e os objetos de interesse baseia-se no componente de intensidade  $I$  do espaço  $HSI$ . A média das intensidades dos pixels revela-se como um bom parâmetro de limiarização para a segmentação, como pode ser observado na Figura 3.15-(b). Uma vez que o fundo é mais claro que as células, valores maiores que o limiar de intensidade média são de fundo, caso contrário, são de objetos de interesse.

Depois da separação das células do resto da imagem, certas células apresentam-se não preenchidas, o que poderá no futuro dificultar o reconhecimento das mesmas. A partir das bordas físicas da imagem (marcador), o processo de Reconstrução morfológica Binária [Fac96] preenche todo o fundo da imagem limiarizada invertida (máscara) sem preencher os microorganismos. Invertendo o resultado anterior, gera-se a imagem das células no seu formato original totalmente preenchidas sem deformação. Os resíduos de fundo são eliminados por processos morfológicos Binários (reconstrução e erosão e dilatação) (Figura 3.15-(c)).

A separação automática das células faz-se usando o mesmo mecanismo anteriormente apresentado. Primeiramente gerando uma imagem distância pela abordagem de Chamfer 5/7/11, depois localizando os núcleos computacionais por reconstrução morfológica em níveis de cinza (Figura 3.15-(d)) e por fim rotulando das células por Watershed (Figura 3.15-(e)).

Tendo as células sido rotuladas, e, portanto, reconhecidas univocamente, passe-se, agora, à sua "rotulação" em termos de cor. Usou-se as matizes  $I$  do modelo  $HSI$  para

separar a matiz azul da matiz marrom (Figuras 3.15-(f) e (g)). E assim diferenciar as células não proliferantes das proliferantes.



**Figure 3.15. Separação de células benignas e malignas: (a) Imagem original, (b) Segmentação inicial, (c) Preenchimento e filtragem, (d) Distância de Chamfer 5/7/11, (e) Separação automática por Watershed, (f) Extração das células não proliferantes, (g) Extração das células proliferantes**

## References

- [Ber86] J. Bernsen. Dynamic thresholding of gray-level images. *Proc. Eighth Int'l Conf. Conf. on Pattern Recognition, Paris, France*, pages 1251–1255, 1986.
- [Beu77] S. Beucher. Random process simulation on the texture analyser. *Lecture Notes in Biomathematics*, 23, 1977.
- [BM93] S. Beucher and F. Meyer. The morphological approach to segmentation: the watershed transformation. *Mathematical Morphology in Image Processing*, 1993.
- [Bor84] G. Borgefors. Distance transformation in arbitrary dimensions. *Computer Vision Graphics Image Processing*, 27:321–345, 1984.
- [Bor86] G. Borgefors. Distance transformation in digital image. *Computer Vision Graphics Image Processing*, 34:344–371, 1986.
- [Can83] J. F. Canny. Finding edges and lines in images. Technical report, MIT, <http://www.mit.edu/>, 1983.
- [CDG92] B. Costa, L. Darsa, and J.M. Gomes. Image metamorphosis. *V Simpósio Brasileiro de Computação Gráfica e Processamento de Imagens*, pages 19–27, 1992.
- [CM] B. Chanda and D.D. Majunder. A note on the use of the graylevel co-occurrence matrix in threshold selection. *Signal Processing*.
- [CZ99] Qian Chen and Baomin Zhang. Image enhancement based on equal area dualist sub-image histogram equalization method. *IEEE Transactions on Consumer Eletronics*, 45(1):65–78, February 1999.
- [DCT95] G. Deng, W. Cahill, and G. R. Tobin. The study of logarithmic image processing model and its application to image enhancement. *IEEE Transactions on Image Processing*, 4(4):506–512, April 1995.
- [Der87] R. Deriche. Optimal edge detection using recursive filtering. *International Journal of Computer Vision*, 1987.
- [Dou81] J.G. Douglas. The role of human visual models in image processing. *Proceedings of the IEEE*, 69(5):552–561, May 1981.
- [Duf86] M. J. B. Duff. *Intermediate-level Image Processing*. Academic Press, 1986.
- [Fac96] Jacques Facon. *Morfologia Matemática: Teoria e Exemplos*. J. Facon Editor, Curitiba-PR, 1996.
- [Fac01] Jacques Facon. Repositório de algoritmos de segmentação por binarização. Technical report, Pontifícia Universidade Católica do Paraná, PUCPR, Curitiba-Brasil, [http : //www.ppgia.pucpr.br/~facon/IndexPrincipalBrBinarizacao.htm](http://www.ppgia.pucpr.br/~facon/IndexPrincipalBrBinarizacao.htm), 2001.

- [FF87] M.A. Fischler and O. Firschein. *Intelligence, the eye, the brain and the computer*. Addison Wesley, 1987.
- [HSZ87] R.M Haralick, S.R Sternberg, and X. Zhuang. Image analysis using mathematical morphology. *IEEE Transactions On Pattern Analysis and Machine Intelligence*, PAMI 9(4):532–550, July 1987.
- [J03] Gerson Carlos Bochnia Júnior. Sistema de localização e contagem automática de microorganismos em imagens microscópicas de levedura de cerveja. Technical report, Pontifícia Universidade Católica do Paraná, PUCPR, Curitiba-Brasil, 2003.
- [Kim96] Yeong-Taeg Kim. Contrast enhancement using brightness preserving bi-histogram equalization. *IEEE*, pages 1–8, 1996.
- [Kim97] Yeong-Taeg Kim. Quantized bi-histogram equalization. *IEEE*, pages 1–4, 1997.
- [KKH00] Joung Youn Kim, Lee Sup Kim, and Seung Ho Hwang. An advanced contrast enhancement using partially overlapped sub-block histogram equalization. *IEEE International Symposium on Circuits and Systems, ISCAS*, 1:537–540, May 2000.
- [KPKPR99] B Kangar-Parsi, B. Kangar-Parsi, and A. Rosenfeld. Optimally isotropic laplacian operator. *IEEE Transactions on Image Processing*, 10(8):1467–1472, October 1999.
- [Mar82] D. Marr. *Vision*. Freeman, 1982.
- [Mar00] P.R. Martins. *Segmentação de Histogramas Multimodias: Simulações, Implementações e Aplicação em Cheques Bancários Brasileiros*. Master Thesis- PUCPR-Curitiba-Brazil, November 2000.
- [MV89] N.D.A. Mascarenhas and F.D.R. Velasco Velasco. *Processamento Digital de Imagens. 2ª edição*. IV Escola Brasileiro-Argentina de Informática, Termas de Rio Hondo, Argentina, 1989.
- [NM79] M. Nagao and T. Matsuyama. Edge preserving smoothing. *Computer Graphics and Image Processing*, 13:394–407, 1979.
- [NR78] Y. Nakagawa and A. Rosenfeld. A note on the use of local min and max operations in digital picture processing. *IEEE Transactions on Systems, Man and Cybernetics*, 8, 1978.
- [Ots79] N. Otsu. A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man and Cybernetics*, SMC 9(1):62–66, April 1979.
- [Ros88] A. Rosenfeld. Computer vision: Basic principles. *Proceedings of the IEEE*, 76(8):863–868, August 1988.

- [Ser82] J. Serra. *Image Analysis and Mathematical Morphology*. Academic Press, London, 1982.
- [Shi] Ando Shigeru. Consistent gradient operators. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- [Shi87] Y. Shirai. *Three Dimensional Computer Vision*. Springer-Verlag, 1987.
- [Web97] Andréa Weber. Avaliação da proliferação celular baseada em pcna-ciclina por análise morfológica aplicada a linfomas malignos não-hodgkin. Technical report, Centro Federal de Educação Tecnológica do Paraná, CEFETPR, Curitiba-Brasil, [http : //www.ppgia.pucpr.br/~facon/IndexPrincipalBrTeses.htm](http://www.ppgia.pucpr.br/~facon/IndexPrincipalBrTeses.htm), 1997.
- [Wel93] P.D Wellner. Adaptative thresholding for the digitaldesk. *Technical Report EPC-1993-110, Rank Xerox Ltd*, July 1993.
- [YCC95] J.C. Yen, F.J. Chang, and S. Chang. A new criterion for automatic multi-level thresholding. *IEEE Transactions on Image Processing*, 4(3):370–378, March 1995.



Jacques Facon é Professor e Pesquisador no Programa de Pós-Graduação em Informática Aplicada (PPGIA) da Pontifícia Universidade Católica do Paraná (PUCPR).

Formou-se como doutor em Processamento e Análise de Imagens pela Université de Technologie de Compiègne na França em 1987.

Suas áreas atuais de interesse incluem processamento de imagens, morfologia matemática, reconhecimento de padrões e visão computacional.